

Identificação de datasets relacionados, em contexto com metadados ausentes ou parciais

Sérgio Bernardelli Netto

PROJETO FINAL DE GRADUAÇÃO

CENTRO TÉCNICO CIENTÍFICO - CTC

DEPARTAMENTO DE INFORMÁTICA

Curso de Graduação em Ciência da Computação

Rio de Janeiro, Novembro de
2024



Sérgio Bernardelli Netto

**Identificação de datasets relacionados, em contexto com
metadados ausentes ou parciais**

Relatório de Projeto Final, apresentado ao
programa Ciência da Computação da PUC-Rio
como requisito parcial para a obtenção do título de
Bacharel em Ciência da Computação.

Orientador: Marcos Vianna Villas

Rio de Janeiro, Novembro de 2024

Resumo

Bernardelli Netto, Sérgio. Vianna Villas, Marcos. Título e subtítulo. Rio de Janeiro, 2024. Número de páginas p. Relatório Final de Projeto Final I – Departamento de Administração. Pontifícia Universidade Católica do Rio de Janeiro.

O projeto irá propor metodologias e ferramentas para a análise, identificação e determinação de possíveis combinações de datasets, seja pela identificação de chaves estrangeiras entre dois datasets, seja pela similaridade entre datasets. Serão utilizadas técnicas de mineração de dados e aprendizado de máquina, entre outras. Os resultados obtidos pelo projeto poderão viabilizar novas análises de dados com a utilização de datasets que anteriormente não se apresentavam como relacionados, em um determinado contexto.

Palavras-chave

Identificação de datasets, metadados ausentes, metadados parciais, mineração de dados, aprendizado de máquina, dependências funcionais relaxadas, data lakes e automação de ligações.

Abstract

Bernardelli Netto, Sérgio. Vianna Villas, Marcos. Identification of Related Datasets in the Context of Missing or Partial Metadata. Rio de Janeiro, 2024. Número de páginas p. Relatório Final de Projeto Final I – Departamento de Administração. Pontifícia Universidade Católica do Rio de Janeiro.

This project proposes methodologies for analyzing, identifying, and determining potential combinations of datasets, focusing on the discovery of foreign keys or similarities between datasets with missing or partial metadata. The approach leverages data mining and machine learning techniques to automate the correlation process between tables. By doing so, the project aims to enable new forms of data analysis that were previously unattainable due to the lack of explicit relationships between datasets. The results are expected to enhance data integration and uncover insights in contexts where datasets appeared unrelated.

Keywords

dataset identification, missing metadata, partial metadata, data mining, machine learning, relaxed functional dependencies, data lakes, and correlation automation.

Índice

1. Introdução -----	5
2. Situação Atual -----	6
3. Objetivos -----	8
4. Plano de Ação -----	9
5. Cronograma -----	12
6. Proposta Inicial -----	13
7. Referências -----	16

1. Introdução

Com o aumento significativo da quantidade de dados disponíveis em diversos setores, a gestão eficiente e a correta interpretação desses dados se tornaram desafios cruciais. Em muitos cenários, os dados estão distribuídos em diferentes conjuntos de datasets, sejam eles tabelas pertencentes a um esquema de banco de dados tradicional ou arquivos armazenados em *data lakes*¹, sendo estes representações de uma abordagem alternativa aos armazéns de dados tradicionais, permitindo o armazenamento de dados em sua forma original e sem a necessidade de esquemas rígidos. No entanto, essa flexibilidade também traz desafios significativos, como a possibilidade de o repositório se tornar um *data swamp*, com dados de difícil organização e acesso sem metadados robustos. As tabelas de um esquema de banco de dados geralmente contam com chaves estrangeiras (FKs) previamente definidas, o que facilita a identificação da relação entre elas. No entanto, em ambientes de *data lakes*, onde os dados são frequentemente ingeridos sem metadados adequados, a situação é mais complexa. Quando esses *data lakes* carecem de organização e descrição de seus dados, transformam-se em verdadeiros *data swamps*, dificultando a identificação de ligações entre conjuntos de dados.

A falta de metadados estruturados, seja em tabelas de bancos de dados com FKs ou em *data lakes*, representa um obstáculo crítico para a identificação de ligações entre datasets. Sem esses metadados, relacionar as informações se torna uma tarefa manual e propensa a erros, especialmente quando se lida com grandes volumes de dados dispersos.

Portanto, a falta de metadados é um problema real que impede o aproveitamento total das potencialidades dos dados, limitando a capacidade de realizar análises aprofundadas. A ausência de mecanismos automatizados para identificar possíveis combinações de datasets e chaves estrangeiras, assim como a similaridade entre datasets, afeta diretamente a qualidade das análises e a eficiência das operações de integração de dados.

¹ *Data lakes* representam uma abordagem alternativa aos armazéns de dados tradicionais, permitindo o armazenamento de dados em sua forma original e sem a necessidade de esquemas rígidos. No entanto, essa flexibilidade também traz desafios significativos, como a possibilidade de o repositório se tornar um *data swamp*, com dados de difícil organização e acesso sem metadados robustos (Khine & Wang, 2018).

2. Situação Atual

A situação atual da automação da identificação de ligações entre bancos de dados envolve o uso de técnicas sofisticadas para otimizar a integração de dados em grandes coleções, especialmente diante de cenários onde os metadados são limitados ou inexistentes. Em sistemas legados, onde tabelas frequentemente não possuem chaves estrangeiras (FKs), a identificação de ligações entre dados é dificultada pela falta de estruturas de referência predefinidas. Para resolver esse desafio, ferramentas como o Metanome (Papenbrock et al., 2015) aplicam algoritmos avançados de perfilamento² para detectar automaticamente dependências complexas, como dependências de inclusão e funcionais, facilitando a análise e a integração de dados.

Nos *data lakes*, onde diversos datasets são colecionados sem uma descrição adequada, o problema se agrava, já que esses repositórios, quando não estruturados, tornam-se *data swamps*, com dados de difícil acesso e pouca usabilidade. Ferramentas de *AutoML* - sistemas que são capazes de automatizar processos complexos de aprendizado de máquina, e adaptadores como o EM, que permitem automatizar tarefas de aprendizado de máquina para simplificar a correspondência de registros que representem objetos únicos em diferentes datasets, tornando mais acessível a identificação de registros duplicados em grandes volumes de dados (Papadakis et al., 2021). O uso de dependências funcionais relaxadas (RFDs) complementa essa abordagem, estendendo as dependências clássicas para capturar ligações em dados não padronizados, ou que possam apresentar inconsistências ou erros que prejudiquem análises precisas, viabilizando a integração de dados heterogêneos e a correção automática de inconsistências (Caruccio et al., 2016).

No contexto de dados abertos, algoritmos de busca de similaridade, como o *Locality Sensitive Hashing* (LSH), oferecem uma solução escalável para encontrar tabelas que possam ser relacionadas. Eles melhoram a precisão ao identificar atributos relacionados em bases de dados amplas e descentralizadas, como as governamentais, complementando ferramentas de perfilamento como o Metanome (Bhardwaj et al., 2020).

² *Perfilamento de dados (ou profiling)* refere-se ao processo de examinar um conjunto de dados para extrair metadados relevantes, como padrões, estatísticas e características gerais. Esses metadados incluem dependências, chaves e atributos únicos, que auxiliam na integração e análise de dados heterogêneos (Papenbrock et al., 2015).

A combinação de técnicas como perfilamento de dados, *AutoML*, RFDs e algoritmos de similaridade representa um avanço significativo na automação de ligações complexas entre tabelas e bancos de dados, permitindo uma análise mais rápida e precisa, mesmo em contextos de dados imprecisos e heterogêneos.


3. Objetivos

O principal objetivo deste trabalho é propor metodologias e ferramentas que automatizem a análise, identificação e determinação de possíveis combinações entre diferentes datasets, mesmo em contextos onde os metadados estejam ausentes ou sejam parciais. Especificamente, o projeto visa desenvolver soluções que permitam a identificação de chaves estrangeiras entre dois ou mais datasets, bem como a detecção de similaridades que possam indicar possíveis ligações entre tabelas ou arquivos de dados.

Espera-se que os resultados obtidos viabilizem novas formas de análise de dados, permitindo explorar ligações ocultas ou não evidentes entre datasets que, anteriormente, não se apresentavam como conectados, promovendo assim uma análise mais abrangente e integrada.

4. Plano de Ação

O plano de ação deste trabalho foi estruturado para abordar de forma sistemática as etapas necessárias para o desenvolvimento da metodologia proposta, que visa automatizar a identificação de ligações entre datasets em diferentes contextos. Primeiramente, será realizada uma revisão bibliográfica para embasar teoricamente as técnicas e conceitos envolvidos, como mineração de dados, aprendizado de máquina e dependências funcionais relaxadas. Em seguida, serão apresentadas as principais ferramentas e abordagens técnicas que darão suporte à metodologia. A partir disso, será proposta uma metodologia inicial que será avaliada tanto com conjuntos de datasets quanto por especialistas em análise de dados. Os resultados obtidos dessas avaliações permitirão ajustar a proposta final, que culminará nas conclusões e recomendações do trabalho.



4.1. Revisão Bibliográfica

Nesta etapa, serão reunidos e analisados artigos acadêmicos e outras referências relevantes que tratam de automação de ligações entre bancos de dados, mineração de dados e aprendizado de máquina. O objetivo é entender as técnicas existentes e como elas podem ser aplicadas na automação de ligações entre datasets.

4.2. Apresentação de Conceitos e Técnicas

Aqui serão apresentados os principais conceitos, como dependências funcionais relaxadas (RFDs), *AutoML*, perfilamento de dados e algoritmos de similaridade (*Locality Sensitive Hashing*). Cada técnica será explicada e justificada quanto à sua importância no processo de automação de ligações.

4.3. Proposta Inicial de Metodologia

Esta fase envolve a criação de um esboço inicial da metodologia que será aplicada para identificar ligações entre datasets de diferentes bancos de dados. A proposta incluirá ferramentas e algoritmos que serão usados para descobrir metadados, encontrar chaves estrangeiras e identificar similaridades entre conjuntos de dados. Serão definidos os “casos de identificação” que serão abordados, com possível participação humana para esclarecimentos da existência ou não de ligações entre os dados.

4.4. Avaliação com Conjuntos de Datasets

Testes serão realizados com pelo menos cinco conjuntos de datasets distintos. O foco será avaliar se a metodologia proposta consegue automatizar a identificação de ligações, como chaves estrangeiras ou similaridades. Exemplos de datasets incluem bases de dados públicas.

4.5. Avaliação com Especialistas

Dois especialistas em análise de dados serão convidados para revisar a metodologia proposta e fornecer feedback técnico. Essa avaliação ajudará a validar a aplicabilidade das técnicas e a identificar possíveis melhorias na abordagem.

4.6. Resultados das Avaliações

Nesta etapa, serão organizados os resultados obtidos tanto das avaliações automáticas (com datasets) quanto das avaliações dos especialistas consultados sobre as avaliações automáticas. A análise comparativa dos resultados será feita para identificar possíveis ajustes e melhorias na metodologia inicial.

4.7. Proposta da Metodologia Final

Baseado no feedback dos especialistas e nos resultados dos testes com datasets, a metodologia será refinada, e a proposta final será criada para refletir as melhores práticas e soluções encontradas durante o processo de avaliação.

4.8. Conclusões e Recomendações

O trabalho será finalizado com as conclusões, resumindo os principais achados e sugerindo recomendações práticas para o uso da metodologia em outros contextos. Além disso, serão indicadas possíveis direções para pesquisas futuras ou aprimoramentos no método.

5. Cronograma


Planejamento para 2024.2

	Set24	Out24	Nov24	Dez24
Revisão Bibliográfica	XXX	X		
Apresentação de conceitos e técnicas	X	XX	X	
Proposta inicial de metodologia			XXX	XXXX

Planejamento para 2025.1

	Mar25	Abr25	Mai25	Jun25	Jul25
Avaliação com conjuntos de datasets	XX	XX			
Avaliação com especialistas	XX	X			
Resultados das avaliações		X	XX		
Proposta da metodologia final			XX	XXX	
Conclusões e Recomendações				X	XXXX

6. Proposta Inicial



6.1. Importação dos Datasets

Garantir que os datasets de diferentes fontes sejam acessíveis ao sistema.

Nesta etapa, o programa carrega os datasets provenientes, como tabelas de bancos de dados legados ou arquivos armazenados em um data lake. O processo deve ser capaz de lidar com formatos variados (por exemplo, CSV, JSON ou SQL) e padronizá-los em uma estrutura legível pelo sistema, permitindo que os passos subsequentes sejam realizados sem a necessidade de intervenção manual.

6.2. Perfilamento

Analisar os atributos dos datasets para gerar informações estruturais que auxiliem nas etapas de combinação ou complementação.

O perfilamento consiste em explorar as características dos campos, como tipos de dados, nomes, frequência de valores únicos e possíveis chaves candidatas.

Esses metadados ajudam a compreender a estrutura dos datasets, identificando elementos que podem ser utilizados para encontrar relações ou padrões, seja para complementar os dados ou combinar informações.

6.3. Detecção de Similaridade de Atributos

Identificar atributos compatíveis entre diferentes datasets para permitir combinações ou complementações.

Nesta etapa, o sistema compara os atributos de diferentes datasets para identificar atributos compatíveis - colunas que apresentam semelhanças baseadas em características como nome, formato ou distribuição de valores e que podem ser usadas conjuntamente em análises ou operações - esses atributos podem representar potencial para relações ou viabilizar operações como união, interseção ou diferença entre os datasets.

Quando metadados explícitos, como chaves primárias e chaves estrangeiras, são encontrados durante a análise, eles são utilizados para validar ou aprimorar as detecções realizadas. Esses metadados, quando disponíveis, são incorporados no mapeamento geral para enriquecer as possibilidades de combinação e garantir a confiabilidade das associações geradas.

6.4. Validação

Verificar e validar as compatibilidades detectadas, garantindo que as combinações ou complementações entre datasets sejam confiáveis.

Após a detecção de atributos compatíveis, o sistema realiza uma validação para assegurar que as correspondências identificadas são consistentes e aplicáveis. Esta etapa envolve a análise cruzada dos valores dos atributos compatíveis para confirmar se as relações ou complementaridades sugeridas fazem sentido no contexto dos dados. Por exemplo, no caso de chaves estrangeiras, verifica-se se os valores no dataset dependente correspondem a valores existentes na chave primária referenciada.

A etapa de validação serve como um filtro essencial para assegurar a qualidade dos resultados antes que os dados avancem para a identificação de ligações.

6.5. Identificação de Relações Implícitas

Descobrir conexões entre os datasets, mesmo que essas relações não sejam explicitamente documentadas.

Nesta etapa, o programa analisa os campos que apresentaram similaridades para determinar ligações. São investigadas possíveis conexões que indiquem dependências entre os datasets, como chaves estrangeiras, ou ligações que permitam operações de combinação.

6.6. Ajustes

Refinar as combinações ou complementaridades identificadas para garantir a máxima utilidade e usabilidade dos dados processados.

Nesta etapa, o sistema realiza ajustes nas compatibilidades previamente validadas, com foco em refinar as sugestões de combinações ou complementaridades. Caso existam pequenas discrepâncias ou formatos divergentes, são aplicadas transformações nos dados para harmonizá-los e torná-los mais alinhados aos padrões necessários para análise ou integração.

Os ajustes também incluem a adaptação das combinações identificadas para cenários específicos, como a preparação de operações de união, interseção ou diferença entre datasets. Esses refinamentos são feitos de forma automatizada sempre que possível, com a possibilidade de intervenção manual quando necessário, assegurando que os resultados sejam prontos para uso em análises mais profundas ou integrações sistêmicas.

6.7. Resumo das Ligações Encontradas

Consolidar as conexões descobertas entre os datasets em um formato claro e acessível.

O sistema apresenta um relatório com o resumo das ligações identificadas, incluindo combinações possíveis (união, interseção, diferença) e complementações (chaves estrangeiras ou dependências). Este resumo serve como um guia para que os dados possam ser utilizados de forma mais integrada, facilitando análises futuras e viabilizando o uso de dados que antes não eram considerados relacionados.

7. Referências

CARUCCIO, Loredana; DEUFEMIA, Vincenzo; POLESE, Giuseppe. Relaxed functional dependencies—a survey of approaches. **IEEE Transactions on Knowledge and Data Engineering**, v. 28, n. 1, p. 147-165, 2015.

KHINE, Pwint Phyu; WANG, Zhao Shun. Data lake: a new ideology in big data era. In: **ITM web of conferences**. EDP Sciences, 2018. p. 03025.

MILLER, Renée J. et al. Making Open Data Transparent: Data Discovery on Open Data. **IEEE Data Eng. Bull.**, v. 41, n. 2, p. 59-70, 2018.

PAPENBROCK, Thorsten et al. Data profiling with metanome. **Proceedings of the VLDB Endowment**, v. 8, n. 12, p. 1860-1863, 2015.

PAGANELLI, Matteo et al. Automated machine learning for entity matching tasks. In: **Advances in Database Technology-EDBT 2021, 24th International Conference on Extending Database Technology, Nicosia, Cyprus, March 23-26, Proceedings**. OpenProceedings.org, 2021. p. 325-330.